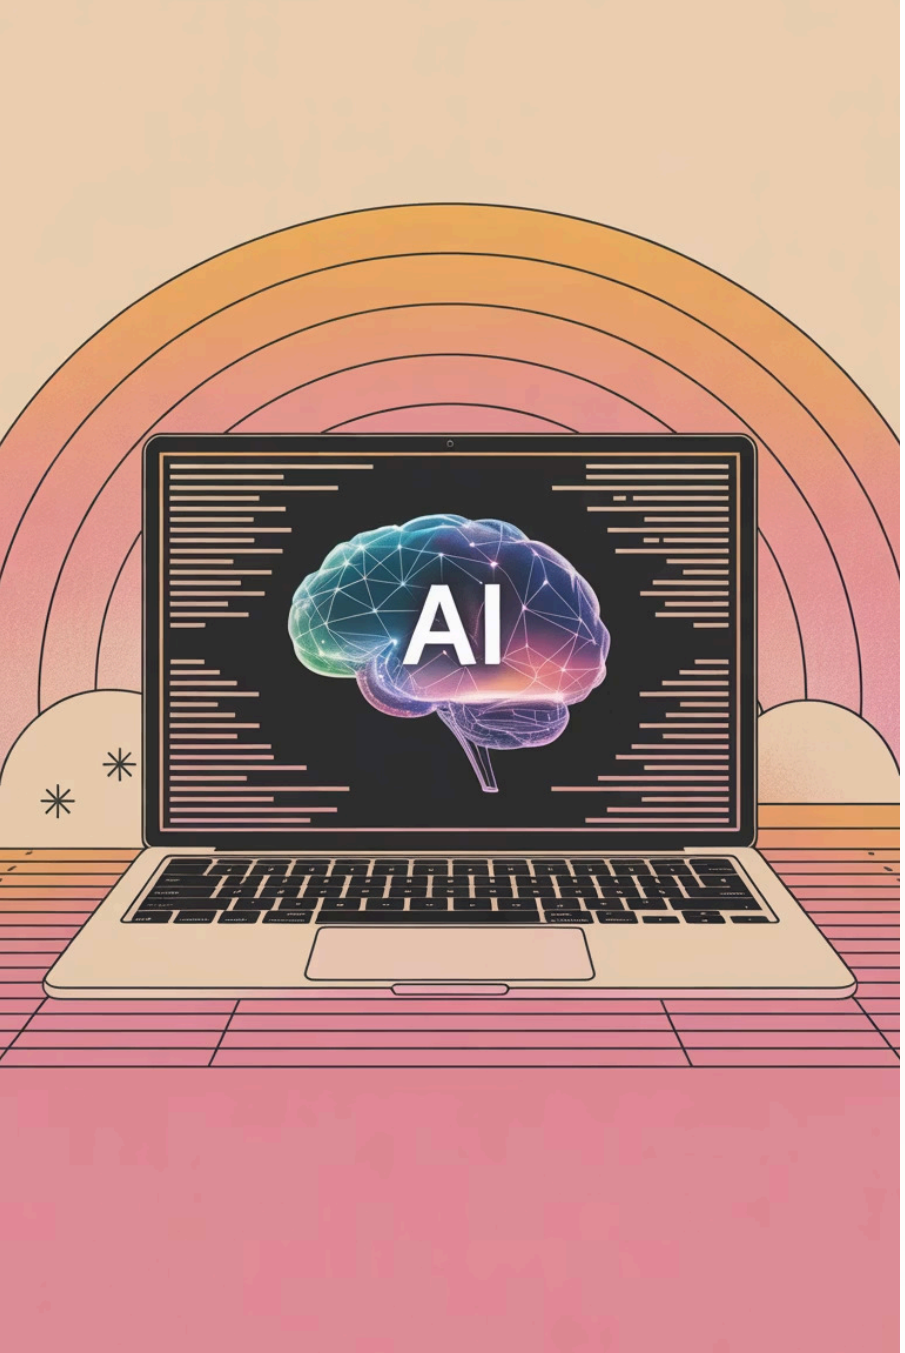

TALLER: Modelos Locales de IA

¡Tu asistente de IA ahora en tu ordenador! Ejecuta la Inteligencia Artificial en tu Propio Ordenador

Modelos de IA: Local vs. Nube

Un **modelo de IA** es un algoritmo entrenado para realizar tareas específicas, actuando como su "cerebro". ¿Dónde lo ejecutas?

Modelo Local

Se ejecuta directamente en tu ordenador, usando sus recursos.

- **Privacidad total:** Tus datos no salen de tu máquina.
- **Control absoluto:** Gestionas el modelo y su acceso.
- **Sin internet:** Funciona sin conexión.
- **Inversión inicial:** Hardware, sin suscripciones.

Modelo en la Nube

Acceso a través de servidores remotos de proveedores (ej. OpenAI).

- **Menos hardware:** No necesitas equipo potente.
- **Modelos avanzados:** Acceso a las últimas versiones.
- **Conexión obligatoria:** Requiere internet constante.
- **Costos recurrentes:** Basado en uso o suscripción.

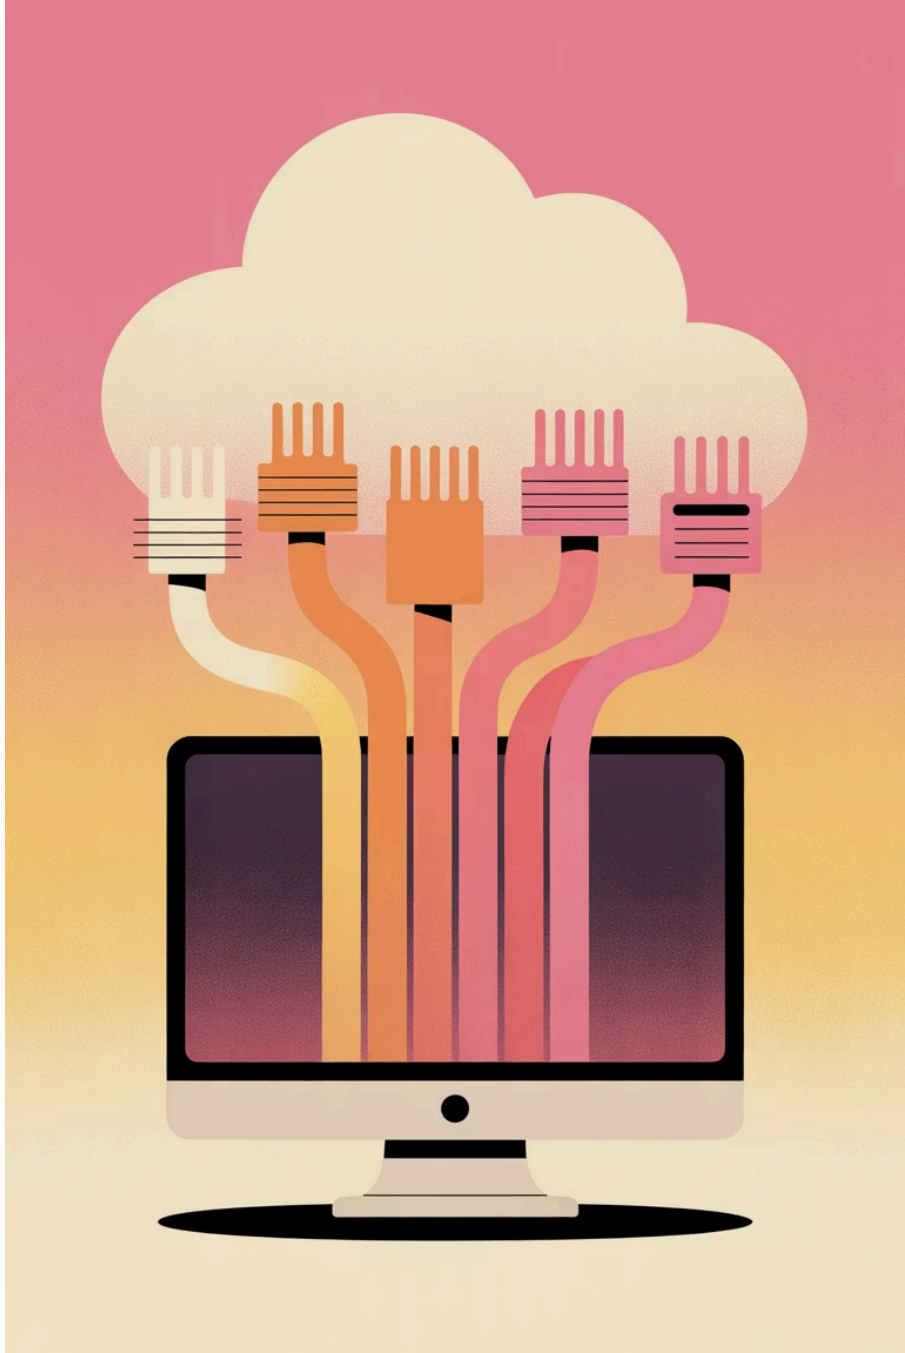

Control Total

Los modelos locales de IA ofrecen control, privacidad y autonomía al ejecutarse directamente en tu equipo.

Privacidad Total 🔒

Tus datos permanecen seguros en tu equipo, ideal para información sensible.

Uso Ilimitado y Gratuito

Una inversión inicial para un uso ilimitado y sin suscripciones.

Funciona 100% Offline 📡

Opera sin conexión a internet, ideal para trabajar en cualquier lugar.

Personalización Completa

Ajusta el modelo a tus necesidades con control total sobre los parámetros.

La estrategia óptima es **combinar ambos**: la nube para potencia en tareas complejas y lo local para datos sensibles y personalización.

Conceptos técnicos básicos

1

Parametros(B):

El "tamaño del cerebro" del modelo. Se mide en miles de millones (3B, 7B, 13B).

2

RAM Necesaria

Necesitas aproximadamente el doble de RAM que el tamaño del modelo. Regla simple: 3B → 8GB RAM.

3

Contexto (Tokens)

La "memoria" de la conversación que tiene el modelo.

4

Procesador (CPU):

Tu procesador (la CPU) decide lo rápido que el programa puede darte respuestas

Instalación de Ollama: Guía Paso a Paso

Descarga e Instala

Visita el sitio oficial de Ollama y descarga el instalador para tu sistema operativo (macOS, Windows o Linux): **https://ollama.com/download**

Ejecuta Ollama

Una vez instalado, abre Ollama. Se ejecutará en segundo plano, listo para recibir tus comandos.

Descarga tu Primer Modelo

Abre tu terminal y escribe `ollama run llama2` (o el modelo que prefieras). Ollama lo descargará automáticamente.

¡A Chatear!

Una vez descargado, el modelo se ejecutará y podrás empezar a interactuar con él directamente desde la terminal. ¡Tu IA local está lista!

Comandos de Ollama:

- `ollama list` - Ver todos los modelos descargados
- `ollama --help` - listado de comandos
- `ollama pull <modelo>` - Descargar un modelo sin ejecutarlo
- `ollama run <modelo>` - Ejecutar un modelo (y descargarlo si no lo tienes)
- `ollama show <modelo>` - Ver información detallada de un modelo
- `ollama rm <modelo>` - Eliminar un modelo para liberar espacio

Una vez cargado el modelo veremos en la terminal:

```
>>> Send a message (/? for help)
```

y para salir:

```
>>> /bye
```

Los 4 Modelos de Inicio

1

Phi3 Mini

`phi3:mini`

El **campeón de la eficiencia** de Microsoft. Optimizado para hardware limitado (2-3 GB), destaca en razonamiento lógico, análisis de código y respuestas concisas.

- **Ideal para:** 4-8 GB de RAM
- **Fortaleza:** Rapidez y eficiencia en recursos
- **Mejor uso:** Análisis de código, debugging rápido

2

Llama 3.2

`llama3.2:3b`

Modelo equilibrado de Meta. Destaca por su **excelente español** y conversaciones coherentes. Ideal para 8 GB de RAM.

- **Ideal para:** Uso diario y aprendizaje
- **Fortaleza:** Multilingüe (español)
- **Mejor uso:** Tutorías, explicaciones

3

Gemma 3

`gemma3:4b`

Modelo de Google diseñado para **tareas de programación**. Sobresale en generación de código, explicación de algoritmos y resolución de problemas técnicos.

- **Ideal para:** Programadores
- **Fortaleza:** Generación y análisis de código
- **Mejor uso:** *Pair programming*, revisión de código

4

Mistral 7B ⭐

`mistral:7b`

Nuestra **recomendación principal**. Ofrece el mejor equilibrio rendimiento-calidad. Desarrollado por Mistral AI, compite con modelos más grandes.

- **Ideal para:** 16 GB+ de RAM
- **Fortaleza:** Mejor rendimiento-tamaño
- **Mejor uso:** Análisis complejos, conversaciones extensas

Comienza instalando el modelo que corresponda a tu RAM disponible. Una vez familiarizado con el sistema, experimenta descargando otros modelos para comparar su rendimiento en tus casos de uso específicos. Cada modelo tiene personalidad y fortalezas únicas.

¿Qué Modelo Elijo Según Mi RAM?

La Decisión más Práctica para Empezar

Elegir el modelo correcto es fundamental para una experiencia exitosa. Esta tabla te ayudará a tomar la decisión según tu configuración de hardware disponible:

Tu RAM (GB)	Modelos Seguros	Comando Ollama	Observaciones
4-6 GB	**Phi3 Mini**	`phi3:mini`	Tu única opción realista. Muy optimizado y sorprendentemente capaz para su tamaño.
8 GB	**Llama 3.2**	`llama3.2:3b`	Excelente equilibrio entre velocidad y calidad. Ideal para uso diario y aprendizaje.
16 GB	**Mistral 7B**	mistral:7b	El *sweet spot* de potencia y recursos. Recomendación principal para portátiles modernos.
32 GB+	**Mistral/Llama 13B**	`mistral:7b` o `llama3.2:13b`	Puedes experimentar con modelos más grandes para obtener respuestas de mayor calidad y coherencia.

Cómo Verificar tu RAM Disponible

- **Windows:** Administrador de Tareas → Rendimiento → Memoria
- **macOS:** Monitor de Actividad → Memoria
- **Linux:** Comando `free -h` en terminal

Consejos para Optimizar

- Cierra aplicaciones pesadas antes de ejecutar modelos
- Comienza con el modelo más pequeño y prueba progresivamente
- Monitoriza el uso de RAM durante la ejecución

Resumen

Herramientas Clave 🛠️

- **Ollama:** Gestor de modelos por línea de comandos. Ligero, rápido y perfecto para automatización y scripts

Proceso de Instalación

1. Descarga la herramienta según tu sistema operativo (Windows/macOS/Linux)
2. Instala siguiendo el asistente estándar
3. Ejecuta un comando simple: `ollama run mistral:7b`
4. El sistema descarga y ejecuta automáticamente el modelo

Revisar Código Sensible

Analiza código propietario o confidencial sin riesgo de filtraciones. Tu código nunca sale de tu máquina.

Pair Programming Ilimitado

Sesiones extensas de programación colaborativa sin límites de mensajes ni costes adicionales.

Aprender y Experimentar

Prueba diferentes configuraciones, parámetros de generación y técnicas de *prompting* sin restricciones.